Bid Data / Lab04

TEAM KAPPA

WEIDELE, PRÜLL, TOMONDY, BAUER

HDInsight cluster

HDInsight-Cluster erstellen

Grundlagen	Speicher	Sicherheit +	Netzwerkbetrieb	Konfiguration + Preise	Tags Bewerten +	erstellen			
Neu bei HDInsight? Starten Sie mit unseren Schulungsressourcen Erstellen Sie einen verwalteten HDInsight-Cluster. Treffen Sie Ihre Auswahl zwischen Spark, Kafka, Hadoop, Storm und vielen anderen. Weitere Informationen									
Projektdetails									
Wählen Sie das Abonnement aus, um bereitgestellte Ressourcen und Kosten zu verwalten. Verwenden Sie Ressourcengruppen wie z. B. Ordner zum Organisieren und Verwalten all Ihrer Ressourcen.									
Abonnement *			Azure für Bildungseinrichtungen						
Ressourcengruppe *			Meine-Ressourceng	ruppe		~			
			Neues Element erstellen						
Clusterdetails									
Benennen Sie Ihren Cluster, wählen Sie eine Region sowie einen Clustertyp und eine Clusterversion aus. Weitere Informationen									
Clustername *			Lab04-Cluster			~			
Region *			Deutschland, Wester	n-Mitte		~			
Clustertyp *			Spark Änderung						
Version *	+		Spark 2.4 (HDI 4.0)			~			
Clusteranmeldeinformationen									
Geben Sie neue Anmeldeinformationen ein, die zur Verwaltung oder für den Zugriff auf den Cluster verwendet werden.									
Benutzername fü	ir Clusteranme	eldung * i	admin						
Kennwort für Clu	ısteranmeldur	ıg *	•••••			~			
Clusteranmeldek	ennwort best	ätigen *	•••••			~			
SSH-Benutzername (Secure Shell) * ①			sshuser						
Verwenden Sie e Clusteranmeldek		SH.	✓						

Grundlagen Speicher Sicherheit + Netzwerkbetrieb Konfiguration + Preise Tags Bewerten + erstellen

Konfigurieren Sie Clusterleistung und Preise. Weitere Informationen

Knotenkonfiguration

Konfigurieren Sie Größe und Leistung Ihres Clusters, und zeigen Sie Informationen zu den geschätzten Kosten an.

Die Kostenschätzung in der Tabelle berücksichtigt keine Abonnementrabatte oder Kosten in Zusammenhang mit Speicher, Netzwerk oder Datenübertragung.

i Diese Konfiguration verwendet 38 von 40 verfügbaren Kernen in der Region "Deutschland, Westen-Nutzung von Kernen anzeigen

+ Anwendung hinzufügen

Hauptknoten-K E8 V3 (8 Kerne, 64 GB RAM), 0.64 EUR/Stunde V 2 1.28 EUR	Knotentyp	Knotengröße		Knotenanzahl	Geschätzte Koste
	Hauptknoten-K	E8 V3 (8 Kerne, 64 GB RAM), 0.64 EUR/Stunde	~	2	1.28 EUR
Zookeeper-Knot A2 v2 (2 Kerne, 4 GB RAM), 0.10 EUR/Stunde V 3 0.00 (KOSTENLOS)	Zookeeper-Knot	A2 v2 (2 Kerne, 4 GB RAM), 0.10 EUR/Stunde	~	3	0.00 (KOSTENLOS)
Worker-Knoten E8 V3 (8 Kerne, 64 GB RAM), 0.64 EUR/Stunde V 2 1.28 EUR	Worker-Knoten	E8 V3 (8 Kerne, 64 GB RAM), 0.64 EUR/Stunde	~	2 🗸	1.28 EUR

Automatische Skalierung aktivieren Weitere Informationen

Geschätzte Gesamtkosten/Stunde 2.56 EUR

Skriptaktionen

Verwenden Sie Skriptaktionen zum Ausführen benutzerdefinierter PowerShell- oder Bash-Skripts auf Clusterknoten während der Clusterbereitstellung. Informationen zu Skriptaktionen

+ Skriptaktion hinzufügen

HDInsight-Cluster erstellen



Grundlagen Speicher Sicherheit + Netzwerkbetrieb Konfiguration + Preise Tags Bewerten + erstellen

Spark 2.4 (HDI 4.0) 2.56 EUR Geschätzte Gesamtkosten/Stunde

Diese Schätzung berücksichtigt keine Abonnementrabatte oder Kosten im Zusammenhang mit Speicher, Netzwerk oder Datenübertragung.

Grundlagen

Abonnement Azure für Bildungseinrichtungen
Ressourcengruppe Meine-Ressourcengruppe
Region Deutschland, Westen-Mitte
Clustername (neu) Lab04-Cluster
Clustertyp Spark 2.4 (HDI 4.0)

Benutzername für Clusteranmeldung admin SSH-Benutzername (Secure Shell) sshuser Verwenden Sie ein Aktiviert

Clusteranmeldekennwort für SSH.

Sicherheit + Netzwerkbetrieb

TLS-Mindestversion 1.2

Ressourcenanbieterverbindung Inbound

Verschlüsselung im Ruhezustand Deaktiviert

Verschlüsselung während der Deaktiviert

Übertragung

Verschlüsselung auf dem Host für

temporären Datenträger

Deaktiviert

Speicher

Primärer Speichertyp Azure Storage
Primäres Speicherkonto (neu) lab04storage

Container lab04-cluster-2021-03-28t12-40-21-852z

Zusätzliche Azure Storage-Instanzen Keine
Data Lake Storage Gen1-Zugriff Deaktiviert

Clusterkonfiguration

 Hauptknoten
 2 Knoten, E8 V3 (8 Kerne, 64 GB RAM)

 Zookeeper
 3 Knoten, A2 v2 (2 Kerne, 4 GB RAM)

 Worker
 2 Knoten, E8 V3 (8 Kerne, 64 GB RAM)

4. Explore the cluster

```
sshuser@hn0-lab04: ~
                                                                                                                                                                                                     ×
Microsoft Windows [Version 10.0.19041.867]
(c) 2020 Microsoft Corporation. Alle Rechte vorbehalten.
C:\Users\rolan>ssh sshuser@Lab04-Cluster-ssh.azurehdinsight.net
The authenticity of host 'lab04-cluster-ssh.azurehdinsight.net (20.52.43.207)' can't be established.
ECDSA key fingerprint is SHA256:VNaW4by0WhiouNT/bWbvOkCXWIq2WgAbwFlUr09SsQ0.
Are you sure you want to continue connecting (yes/no)? yes
Warning: Permanently added 'lab04-cluster-ssh.azurehdinsight.net,20.52.43.207' (ECDSA) to the list of known hosts.
Authorized uses only. All activity may be monitored and reported.
sshuser@lab04-cluster-ssh.azurehdinsight.net's password:
Welcome to Ubuntu 16.04.7 LTS (GNU/Linux 4.15.0-1106-azure x86_64)
  * Documentation: https://help.ubuntu.com

* Management: https://landscape.canonical.com

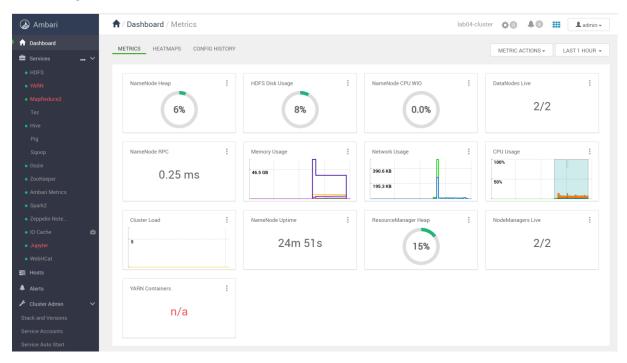
* Support: https://ubuntu.com/advantage
  * Management:
   packages can be updated.
   of these updates are security updates.
 *** /dev/sda1 will be checked for errors at next reboot ***
Welcome to Spark on HDInsight.
The programs included with the Ubuntu system are free software;
the exact distribution terms for each program are described in the
individual files in /usr/share/doc/*/copyright.
Ubuntu comes with ABSOLUTELY NO WARRANTY, to the extent permitted by applicable law.
Welcome to Ubuntu 16.04.7 LTS (GNU/Linux 4.15.0-1106-azure x86_64)
  * Documentation: https://help.ubuntu.com

* Management: https://landscape.canonical.com

* Support: https://ubuntu.com/advantage
  * Support:
   packages can be updated.
 0 of these updates are security updates.
*** /dev/sda1 will be checked for errors at next reboot ***
Welcome to Spark on HDInsight.
The programs included with the Ubuntu system are free software;
the exact distribution terms for each program are described in the
individual files in /usr/share/doc/*/copyright.
Ubuntu comes with ABSOLUTELY NO WARRANTY, to the extent permitted by applicable law.
To run a command as administrator (user "root"), use "sudo <command>".
See "man sudo_root" for details.
  shuser@hn0-lab04:~$ _
```

HDFS

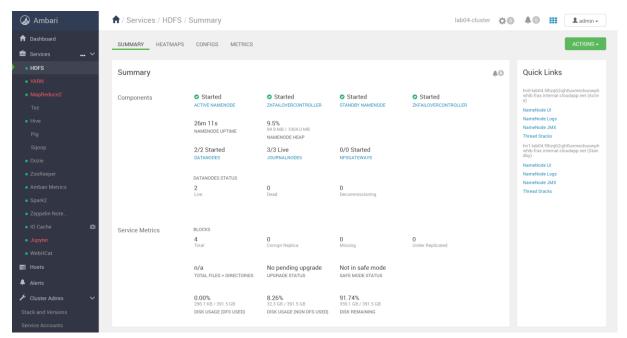
1. Login



2. Explore

hn0-lab04.5lhzqh2ujh0uxmecbuowphwhib.frax.internal.cloudapp.net

hn1-lab04.5lhzqh2ujh0uxmecbuowphwhib.frax.internal.cloudapp.net



3. Connect

```
Shuser@hn0-lab04:~$ ssh hn0-lab04.5lhzqh2ujh0uxmecbuowphwhib.frax.internal.cloudapp.net
The authenticity of host 'hn0-lab04.5lhzqh2ujh0uxmecbuowphwhib.frax.internal.cloudapp.net (10.0.0:16)' can't be establis
hed.
ECDSA key fingerprint is SHA256:VNaW4by0WhiouNT/bWbvOkCXWIq2WgAbwFlUr09SsQ0.
Are you sure you want to continue connecting (yes/no)? yes
Wanning: Permanently added 'hn0-lab04.5lhzqh2ujh0uxmecbuowphwhib.frax.internal.cloudapp.net,10.0.0.16' (ECDSA) to the li
st of known hosts.
Authorized uses only. All activity may be monitored and reported.
sshuser@hn0-lab04.5lhzqh2ujh0uxmecbuowphwhib.frax.internal.cloudapp.net's password:
Welcome to Ubuntu 16.04.7 LTS (GNU/Linux 4.15.0-1106-azure x86_64)

* Documentation: https://help.ubuntu.com
* Management: https://labdascape.canonical.com
* Support: https://ubuntu.com/advantage

0 packages can be updated.
0 of these updates are security updates.
New release '18.04.5 LTS' available.
Run 'do-release-upgrade' to upgrade to it.

*** /dev/sda1 will be checked for errors at next reboot ***

Welcome to Spark on HDInsight.
Last login: Sun Mar 28 13:19:25 2021 from 89.144.206.17
To run a command as administrator (user "root"), use "sudo <command>".
See "man sudo_root" for details.

sshuser@hn0-lab04:~$
```

4. HDFS NameNode

```
See "man sudo_root" for details.

sshuser@hn0-lab04:~$ export HDFS=hdfs://hn0-lab04.5lhzqh2ujh0uxmecbuowphwhib.frax.internal.cloudapp.net
```

5. HDFS MKDIR

```
ssnuser@nno-labo4:~$ export HDFS=nuts://nno-labo4.5inzqnzujnouxmecbuowpnwnib.trax.internal.clouuap
sshuser@hno-labo4:~$ hdfs dfs -mkdir $HDFS/labo4_rolands_dir
sshuser@hno-labo4:~$ wget http://bit.lv/SeattleLibrarvCheckoutRecords
```

6. DOWNLOAD FILES

```
Simuser@inne-labBa1-s waget http://bit.ly/Seattle.libraryCheckoutRecords
-2021-03-28 13:22:30- http://bit.ly/Seattle.libraryCheckoutRecords
Resolving bit.ly (bit.ly)... 67.199.248.11, 67.199.248.11
Gromercing to bit.ly (bit.ly):.. 67.199.248.11, 67.199.248.12
Gromercing to bit.ly (bit.ly):.. 67.199.248.11; 680... connected.
HTP request sent, amalting response... 301 Noved Permanent!
http://propers.com/propers/similary.gr/seattle.library-checkout-records.zip?dl-1 [following]
Localizer Sent. amalting response... 301 Noved Permanent!
Resolving waw.drophox.com (waw.drophox.com)... 162.125.65.18, 2620:108-6022:18::a27d:4212
Connecting to waw.drophox.com (waw.drophox.com)... 162.125.65.18, 2620:108-6022:18::a27d:4212
Localizer Sent. amalting response... 301 Noved Permanently
Location: Sed.dyl.xim.oliceSenTywagssattle-library-checkout-records.zip [following]
--2021-03-28 13:22:36-- https://waw.drophox.com/sed.dyl.xim.oliceSenTywagssattle-library-checkout-records.zip
Resuling existing connection to waw.drophox.com/sed.
HTTP request sent, amalting response... 302 Found
Location: https://uc/Add71633daa122241793029f.dl.drophoxusercontent.com/cd/0/get/BLhAISgnnVmxpx319HZfyJzyM8LSHTbvdbPy0y
kinSzntwq8v18-u2kTDMbdf10PESPM6a131liz9JuoKanLUKXlmx_DSkumYrMkSsEBJGZXLTOz19SxIGIXZARnk1X8qjOKAEAKAP_ImTpX2KtsmdVv/file?
dl=1# [following]
--2021-03-28 13:22:37-- https://uc/Add71633daa132241793d29f.dl.dropboxusercontent.com/cd/0/get/BlhAISgnnVmxpx319HZfyJzyM8LSHTbvdby9ykkinSzntvdgv1B-u2kTDMbdf10PESPM6a31liz9JuoKanLUKXlmx_DSkumYrMkSsEBJGZXLTOz19SxIGIXZARnk1X8qjOKAEAKAP_ImTpX2KtsmdVv/file?
HZRTSmdVv/file?dl=1
VRSTSMdVv/file?dl=1
VRSTSMdVv/file?dl
```

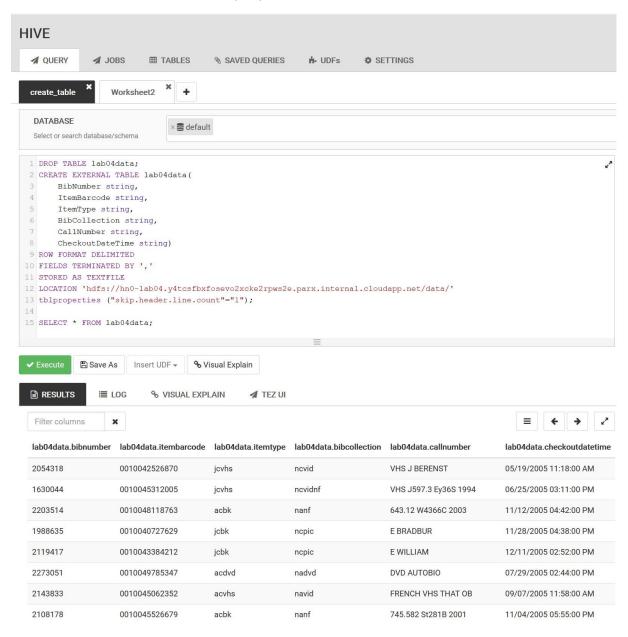
7. HDFS PUT

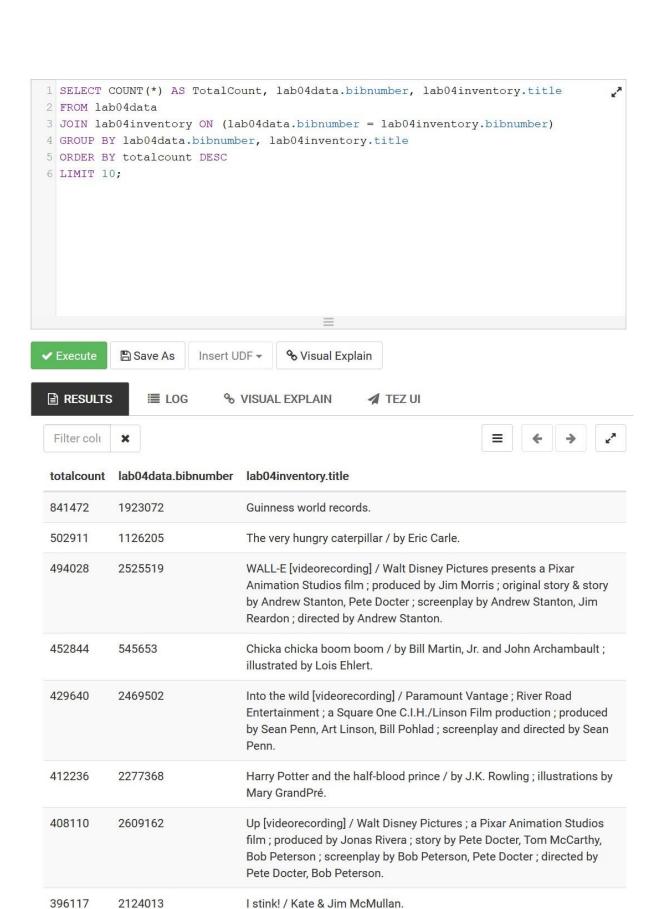
sshuser@hn0-lab04:~\$
sshuser@hn0-lab04:~\$ hdfs dfs -put Checkouts_By_Title_Data_Lens_2016.csv \$HDFS/lab04dir/checkouts/

8. HDFS FSCK

- a. 4
- b. 1
- c. average block size: 115556230 Byte
 - i. Block 1: 10.0.0.6:30010,DS-df4e88cb-8382-4aca-8a4a-ce4d68c3e26c
 - ii. Block 2: 10.0.0.6:30010,DS-df4e88cb-8382-4aca-8a4a-ce4d68c3e26c
 - iii. Block 3: 10.0.0.4:30010,DS-af7231e1-c0fc-4d70-aee1-276805a82901
 - iv. Block 4: 10.0.0.6:30010,DS-df4e88cb-8382-4aca-8a4a-ce4d68c3e26c

9. PLAY AROUND WITH HDFS / query data with HIVE





Green eggs and ham, by Dr. Seuss [pseudonym]

There is a bird on your head! / by Mo Willems.

