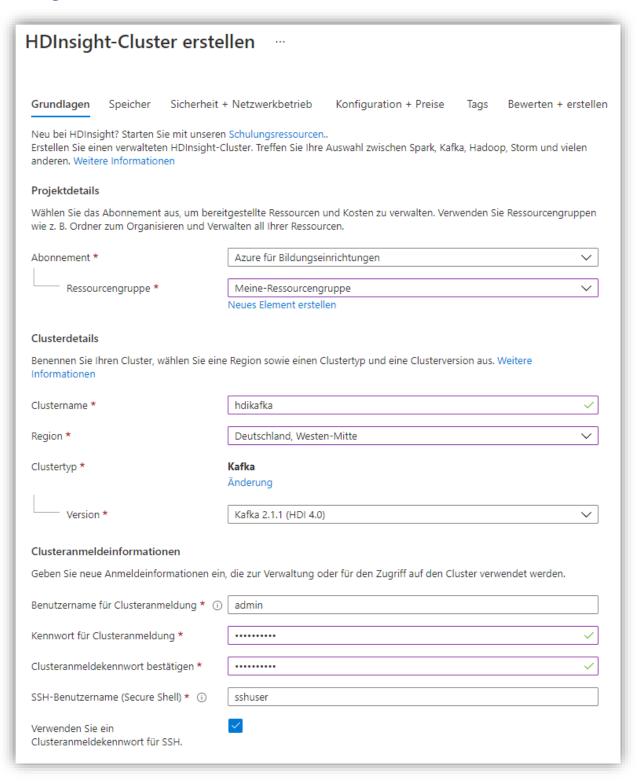
Big Data / Lab05

TEAM KAPPA

WEIDELE, PRÜLL, TOMONDY, BAUER

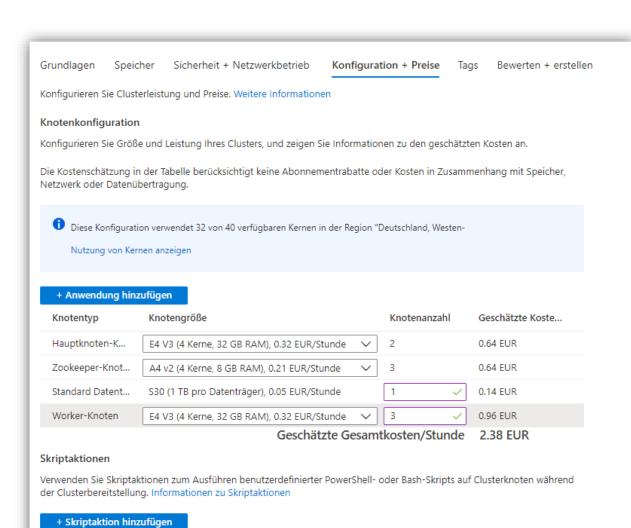
HDInsight cluster

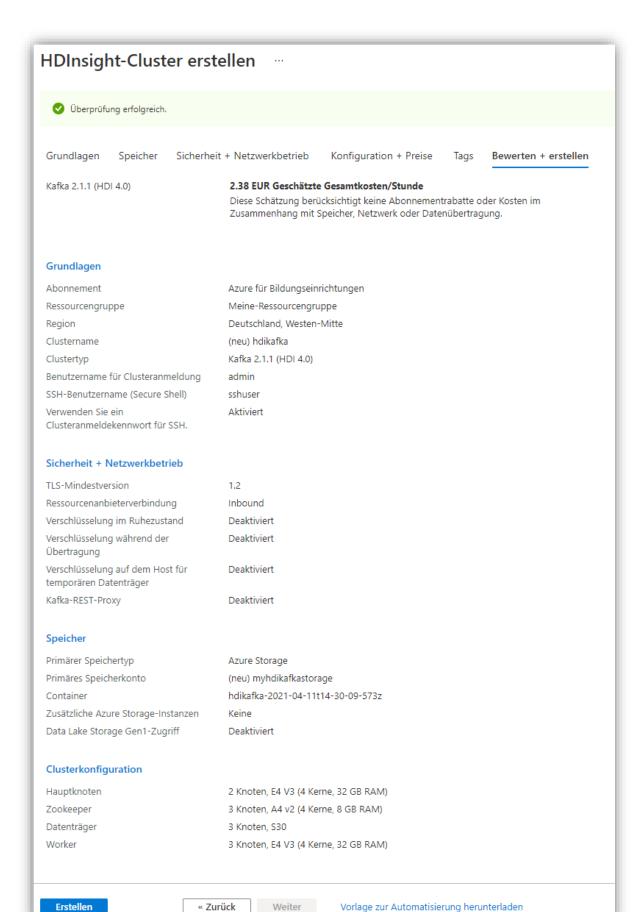


Grundlagen	Speicher	Sicherheit + Netzwerkbetrieb	Konfiguration + Preise	Tags Bewerten + erstellen					
		cherkonten, die für die Protokolle, en Sie bei Bedarf den Zugriff des C		ıftragsausgabe des Clusters					
Primärer Speid	cher								
Wählen oder er: verwendet wird.		peicherkonto, das als Standardspe	icherort für Clusterprotokolle u	nd weitere Ausgabe					
Primärer Speichertyp *		Azure Storage	Azure Storage						
Auswahlmethode * (i)		Aus Liste auswäh	Aus Liste auswählen						
Primäres Speicherkonto *		(Neu) myhdikafkasto	(Neu) myhdikafkastorage						
		Neu erstellen							
Contain	ner* (i)	hdikafka-2021-04-1	hdikafka-2021-04-11t14-30-09-573z						
Data Lake Stor	rage Gen1								
		ils für den Zugriff auf Data Lake St	orage Gen1 an. Der Cluster kan	n auf alle Data Lake Storage					
Geben Sie für den Cluster Details für den Zugriff auf Data Lake Storage Gen1 an. Der Cluster kann auf alle Data Lake Storage Gen1-Konten zugreifen, auf die der ausgewählte Dienstprinzipal zugreifen kann.									
Data Lake Storage Gen1-Zugriff Zugriffseinstellungen konfigurieren									
Zusätzliche Az	zure Storage-I	nstanzen							
Verknüpfen Sie zusätzliche Azure Storage-Konten mit dem Cluster.									
Verknüpfen Sie	_		r.						
Verknüpfen Sie Kontoname	_		r.						
	zusätzliche Azu		r.						
Kontoname	zusätzliche Azu	ire Storage-Konten mit dem Cluste	r.						
Kontoname Azure Storage Benutzerdefin	zusätzliche Azu e hinzufügen iierte Ambari-l eine externe An	ire Storage-Konten mit dem Cluste		und Anpassungsfunktionen.					
Azure Storage Benutzerdefin Verwenden Sie	zusätzliche Azu e hinzufügen iierte Ambari-l eine externe An	re Storage-Konten mit dem Cluste Datenbank		und Anpassungsfunktionen.					
Azure Storage Benutzerdefin Verwenden Sie	zusätzliche Azu e hinzufügen ilerte Ambari-l eine externe An ationen	re Storage-Konten mit dem Cluste Datenbank nbari-Datenbank für mehr Flexibilit		und Anpassungsfunktionen.					
Azure Storage Benutzerdefin Verwenden Sie Weitere Informa	zusätzliche Azu e hinzufügen ilerte Ambari-l eine externe An ationen	re Storage-Konten mit dem Cluste Datenbank nbari-Datenbank für mehr Flexibilit		und Anpassungsfunktionen.					
Azure Storage Benutzerdefin Verwenden Sie Weitere Informa	zusätzliche Azu e hinzufügen iierte Ambari-l eine externe An ationen	re Storage-Konten mit dem Cluste Datenbank nbari-Datenbank für mehr Flexibilit		und Anpassungsfunktionen.					
Azure Storage Benutzerdefin Verwenden Sie Weitere Informa SQL-Datenbank Externe Metad	zusätzliche Azu e hinzufügen sierte Ambari-l eine externe An ationen	re Storage-Konten mit dem Cluste Datenbank nbari-Datenbank für mehr Flexibilit	ät und erweiterte Steuerungs-	~					
Azure Storage Benutzerdefin Verwenden Sie Weitere Informa SQL-Datenbank Externe Metad Um Ihre Hive- u Informationen	zusätzliche Azu e hinzufügen sierte Ambari-l eine externe An ationen c für Ambari ① datenspeicher und Oozie-Meta	re Storage-Konten mit dem Cluste Datenbank nbari-Datenbank für mehr Flexibilit	ät und erweiterte Steuerungs-	~					
Azure Storage Benutzerdefin Verwenden Sie Weitere Informa SQL-Datenbank Externe Metac Um Ihre Hive- u	zusätzliche Azu e hinzufügen sierte Ambari-l eine externe An ationen c für Ambari ① datenspeicher und Oozie-Meta	re Storage-Konten mit dem Cluste Datenbank nbari-Datenbank für mehr Flexibilit	ät und erweiterte Steuerungs-	~					

Grundlagen	Speicher	Sicherheit	+ Netzwerkbetrieb	Konfiguration + Pre	ise Tags	Bewerten + erstellen				
Hiermit werden	Hiermit werden die Sicherheits- und Netzwerkeinstellungen für Ihren Cluster konfiguriert.									
Enterprise-Sicherheitspaket										
Verbinden Sie diesen Cluster mit Active Directory Domain Services (AAD DS), um besser steuern zu können, wer auf den Cluster zugreifen kann. Weitere Informationen										
☐ Enterprise-Sicherheitspaket aktivieren ③(Fügt 0.00885465 EUR pro Kernstunde hinzu.)										
TLS										
Wählen Sie die für Ihren Cluster unterstützte TLS-Mindestversion aus. Weitere Informationen										
TLS-Mindestver	rsion (i)		1.2							
Netzwerkeins	tellungen									
Ressourcenanb	Ressourcenanbieterverbindung ①			Inbound						
Hiermit wird dieser Cluster mit einem virtuellen Netzwerk verbunden. Weitere Informationen										
Virtuelles Netzv	werk ①					~				
			Erstellen eines K möglicherweise	es virtuellen Netzwerks w afka-Clusters ohne virtue unbrauchbar, weil nur vo nts mit den einzelnen Kn	lles Netzwerk w m virtuellen Net	ird der Cluster zwerk aus				
Verschlüsselung während der Übertragung										
Konfigurieren Sie die Einstellungen für die Verschlüsselung während der Übertragung. Weitere Informationen										
Verschlüsse	elung währen	d der Übertrag	gung aktivieren 🛈							
Verschlüsselu	Verschlüsselung im Ruhezustand									
Einstellungen für Datenträgerverschlüsselung konfigurieren Weitere Informationen										
☐ Eigenen Schlüssel aus Key Vault angeben ①										
Verschlüsselung auf dem Host für temporären Datenträger aktivieren ①										
Kafka-REST-Proxy										
Fügen Sie Ihrem Cluster den Kafka-REST-Proxy hinzu.										
Kafka-REST-Proxy aktivieren Weitere Informationen										

Identität Wählen Sie eine benutzerseitig zugewiesene Dienstidentität aus, die Ihren Cluster für das Enterprise-Sicherheitspaket oder die Datenträgerverschlüsselung repräsentiert. Weitere Informationen Benutzerseitig zugewiesene verwaltete Identität ①





Install jq

```
Reading package lists... Done
Building dependency tree
Reading state information... Done
The following package was automatically installed and is no longer required:
libopts25
Use 'sudo apt autoremove' to remove it.
The following additional packages will be installed:
libonig2
The following NEW packages will be installed:
jq libonig2
0 upgraded, 2 newly installed, 0 to remove and 0 not upgraded.
Need to get 231 kB of archives.
After this operation, 797 kB of additional disk space will be used.
Get:1 http://azure.archive.ubuntu.com/ubuntu xenial-updates/universe amd64 libonig2 amd64 5.9.6-lubuntu0.1 [86.7 kB]
Get:2 http://azure.archive.ubuntu.com/ubuntu xenial-updates/universe amd64 jq amd64 1.5+dfsg-lubuntu0.1 [144 kB]
Fetched 231 kB in 08 (1,641 kB/s)
Selecting previously unselected package libonig2:amd64.
(Reading database ... 148314 files and directories currently installed.)
Preparing to unpack .../libonig2.5.9.6-lubuntu0.1_amd64.deb ...
Unpacking libonig2;amd64 (5.9.6-lubuntu0.1) ...
Selecting previously unselected package jq.
Preparing to unpack .../jq_1.5+dfsg-lubuntu0.1_amd64.deb ...
Unpacking jq (1.5+dfsg-lubuntu0.1) ...
Processing triggers for libc-bin (2.23-0ubuntu11.2) ...
Processing triggers for man-db (2.7.5-1) ...

Processing triggers for man-db (2.7.5-1) ...
```

Set up password variable

sshuser@hn0-hdikaf:~\$ export password='PA55W0RD'

Explore the cluster

```
clusterName=$(curl -u admin:$password -sS -G "http://headnodehost:8080/api/v1/clusters
 jq -r '.items[].Clusters.hdikafka')
Jq -r .ltems[].Clusters.ndlka+ka )
sshuser@hn0-hdikaf:.$ export KAFKAZKHOSTS=$(curl -sS -u admin:$password -G https://$clusterName.azurehdinsight.net/api
/v1/clusters/$clusterName/services/ZOOKEEPER/components/ZOOKEEPER_SERVER | jq -r '["\(.host_components[].HostRoles.hos
t_name):2181"] | join(",")' | cut -d',' -f1,2);
curl: (6) Could not resolve host: null.azurehdinsight.net
sshuser@hn0-hdikaf:~$ export clusterName=$(curl -u admin:$password -sS -G "http://headnodehost:8080/api/v1/clusters" |
jq -r '.items[].Clusters.cluster_name')
sshuser@hn0-hdikaf:.$ export cluster_name')
jq -r .items[].Clusters.fluster_name )
sshuser@hnO-hdikaf:~$ export KAFKAZKHOSTS=$(curl -sS -u admin:$password -G https://$clusterName.azurehdinsight.net/api
/v1/clusters/$clusterName/services/ZOOKEEPER/components/ZOOKEEPER_SERVER | jq -r '["\(.host_components[].HostRoles.hos
t_name):2181"] | join(",")' | cut -d',' -f1,2);
sshuser@hnO-hdikaf:~$ echo $KAFKAZKHOSTS
 zkO-hdikaf.mvvuoqfaoyrejgkdjii4ij2lsg.frax.internal.cloudapp.net:2181,zk1-hdikaf.mvvuoqfaoyrejgkdjii4ij2lsg.frax.inter
nal.cloudapp.net:2181
nai.cloudapp.net:zisi
sshuser@hn0-hdikaf:~$ export KAFKABROKERS=$(curl -sS -u admin:$password -G https://$clusterName.azurehdinsight.net/api
/v1/clusters/$clusterName/services/KAFKA/components/KAFKA_BROKER | jq -r '["\(.host_components[].HostRoles.host_name):
9092"] | join(",")' | cut -d',' -f1,2);
sshuser@hn0-hdikaf:~$ echo $KAFKABROKERS
  n0-hdikaf.mvvuoqfaoyrejgkdjii4ij2lsg.frax.internal.cloudapp.net:9092,wn1-hdikaf.mvvuoqfaoyrejgkdjii4ij2lsg.frax.inter
nal.cloudapp.net:9092
sshuser@hn0-hdikaf:~$ /usr/hdp/current/kafka-broker/bin/kafka-topics.sh --create --replication-factor 3 --partitions 8
 --topic test --zookeeper $KAFKAZKHOSTS
Created topic "test".
sshuser@hn0-hdikaf:~$ /usr/hdp/current/kafka-broker/bin/kafka-topics.sh --list --zookeeper $KAFKAZKHOSTS
sshuser@hn0-hdikaf:~$ /usr/hdp/current/kafka-broker/bin/kafka-topics.sh --delete --topic test --zookeeper $KAFKAZKHOST
Topic test is marked for deletion.
Note: This will have no impact if delete.topic.enable is not set to true.
sshuser@hn0-hdikaf:~$ /usr/hdp/current/kafka-broker/bin/kafka-topics.sh --list --zookeeper $KAFKAZKHOSTS
sshuser@hn0-hdikaf:~$ /usr/hdp/current/kafka-broker/bin/kafka-topics.sh --create --replication-factor 3 --partitions 8
 --topic test --zookeeper $KAFKAZKHOSTS
Created topic "test".
sshuser@hn0-hdikaf:~$ /usr/hdp/current/kafka-broker/bin/kafka-topics.sh --list --zookeeper $KAFKAZKHOSTS
test
       ser@hn0-hdikaf:~$ /usr/hdp/current/kafka-broker/bin/kafka-topics.sh
 Create, delete, describe, or change a topic.
                                                                         Description
Option
  -alter
                                                                          Alter the number of partitions,
                                                                             replica assignment, and/or configuration for the topic
   config <String: name=value>
                                                                          A topic configuration override for the
```

Produce records to topic "test"

```
hn0-hdikaf:~$ /usr/hdp/current/kafka-broker/bin/kafka-console-producer.sh --broker-list $KAFKABROKERS --topic
sshuser@nno-ne-
test
>first message
>second message to topic test
>third message to topic test
>last message before quit with ctrl+c ;)

\csp\csshuser@hn0-hdikaf:~$
```

```
ssnusergnnu-nalkat:~$
sshuser@hn0-hdikaf:~$ /usr/hdp/current/kafka-broker/bin/kafka-console-consumer.sh --bootstrap-server $KAFKABROKERS --t
opic test --from-beginning
second message to topic test
last message before quit with ctrl+c ;)
third message to topic test
first message
   `CProcessed a total of 4 messages
sshuser@hn0-hdikaf:~$
```

Create topic "bestellungen"

Python script for sending data to Kafka cluster

```
🔷 send_to_kafka.py > ...
      from kafka import KafkaProducer
      import time
     import os
     producer = KafkaProducer(
          bootstrap_servers=['wn0-hdikaf.mdyd0ctxohzupps0jl0ruvnnxe.frax.internal.cloudapp.net:9092'])
     print("Working on file: " + file)
      file = open(os.path.join(file))
          line = file.readline().rstrip()
          if not line:
              break
              print(line)
              producer.send('bestellungen', line.encode())
          time.sleep(0.001)
      file.close()
      print("end")
```

```
Sshuser@hn0-hdikaf:~/python_scripts$ sshuser@hn0-hdikaf:~/python_scripts$ python3 send_to_kafka.py
Working on file: lab05data.txt

1277134,1,2003-12-02

2435457,2,2005-06-041

2338545,3,2001-02-17

2218269,1,2002-10-11

1921624,2,2005-08-31

2096652,3,2004-05-31

818736,2,2004-05-31

818736,2,2004-09-16

1389539,3,2003-06-09

1494086,1,2004-09-16

1389539,3,2005-06-07

454575,2,2004-06-19

1105843,2,2005-06-19

1105843,2,2005-06-07

353813,2,2006-05-21

639194,2,2003-10-19

308031,4,2000-09-07

1794933,1,2003-02-14

625085,3,2000-12-04

1704675,2,2001-04-10

2116614,3,2002-07-17
```

Python script for consuming data from Kafka cluster

ConsumerRecord(topic='bestellungen', partition=6, offset=127, timestamp=1618668373966, timestamp_type=0, key=None, value=b'403118,3,2005-11-04', headers=[], checksum=None, serialized key_size=-1, serialized value_size=19, serialized_header_size=-1)
ConsumerRecord(topic='bestellungen', partition=0, offset=139, timestamp_type=0, key=None, value=b'1290587,4,2002-03-20', headers=[], checksum=None, serialized key_size=-1, serialized_value_size=20, serialized_header_size=-1)
ConsumerRecord(topic='bestellungen', partition=0, offset=149, timestamp=1618668373973, timestamp_type=0, key=None, value=b'1988192,1,2004-06-07', headers=[], checksum=None, serialized_key_size=-1, serialized_value_size=20, serialized_header_size=-1)
ConsumerRecord(topic='bestellungen', partition=0, offset=149, timestamp=1618668373976, timestamp_type=0, key=None, value=b'865516,1,2005-07-09', headers=[], checksum=None, serialized_key_size=-1, serialized_value_size=19, serialized_header_size=-10
ConsumerRecord(topic='bestellungen', partition=0, offset=148, timestamp=1618668373975, timestamp_type=0, key=None, value=b'819317,3,2005-04-04', headers=[], checksum=None, serialized_key_size=-1, serialized_value_size=19, serialized_header_size=-10
ConsumerRecord(topic='bestellungen', partition=10, offset=150, timestamp=1618668373983, timestamp_type=0, key=None, value=b'18066,2,0005-09', headers=[], checksum=None, serialized_key_size=-1, serialized_value_size=19, serialized_header_size=-10
ConsumerRecord(topic='bestellungen', partition=0, offset=120, timestamp=1618668373984, timestamp_type=0, key=None, value=b'11000081,2005-09', headers=[], checksum=None, serialized_key_size=-1, serialized_value_size=20, serialized_header_size=-1)
ConsumerRecord(topic='bestellungen', partition=0, offset=120, timestamp=1618668373986, timestamp_type=0, key=None, value=b'11000881,2005-06-20', headers=[], checksum=None, serialized_key_size=-1, serialized_value_size=20, serialized_header_size=-1)
ConsumerRecord(topic='bestellungen', partition=0, offset=120, timestamp=16186683739

Bonus Point

Die Retention-Time wurde temporär vom Default-Value (168 Stunden) auf 1000 ms reduziert

- → alle alten Messages sind weg
- → danach Retention-Time wieder erhöht